

Analisis Perbandingan Teknik Resampling SMOTE dan Random Under-Sampling pada Klasifikasi Potensi Dropout Mahasiswa Menggunakan Algoritma XGBoost Universitas Dian Nuswantoro

Muhammad Cahya Kuncoro*¹, Abu Salam M.Kom*²,

Universitas Dian Nuswantoro

e-mail: ¹111202415899@mhs.dinus.ac.id

Abstrak

Tingginya angka putus kuliah (dropout) merupakan tantangan serius bagi institusi pendidikan tinggi. Masalah utama dalam pemodelan machine learning untuk kasus ini adalah dataset riwayat akademik mahasiswa yang umumnya tidak seimbang (imbalanced data), di mana jumlah mahasiswa dropout jauh lebih sedikit dibandingkan yang lulus. Hal ini menyebabkan model cenderung bias dan gagal mendeteksi dini mahasiswa berisiko. Penelitian ini bertujuan untuk menganalisis efektivitas teknik resampling, khususnya SMOTE dan Random Under-Sampling, dalam menangani ketidakseimbangan kelas untuk meningkatkan performa algoritma XGBoost. Eksperimen dilakukan dengan membandingkan model baseline melawan model yang telah diaplikasikan resampling pada tahap pra-pemrosesan. Hasil eksperimen menunjukkan bahwa integrasi algoritma XGBoost dengan SMOTE secara signifikan meningkatkan metrik Recall untuk kelas minoritas dibandingkan model baseline maupun under-sampling. Peningkatan sensitivitas ini membuktikan bahwa metode hibrida tersebut sangat efektif dan stabil untuk diimplementasikan sebagai sistem deteksi dini akademik

Kata kunci: dropout mahasiswa, imbalanced data, resampling, SMOTE, XGBoost

Abstract

Each article in a scientific journal must contain an abstract that is generally only one paragraph (not a summary consisting of several paragraphs) in English (required) and/or Indonesian that is concise, clear, intact, there is no reference to libraries, images, and tables, and fully describes the essence of the entire content of the writing. The high dropout rate poses a serious challenge for higher education institutions. The primary problem in machine learning modeling for this case is that student academic history datasets are generally unbalanced (imbalanced data), where the number of dropout students is significantly lower than those who graduate. This causes models to be biased and fail to detect at-risk students early. This study aims to analyze the effectiveness of resampling techniques, specifically SMOTE and Random Under-Sampling, in handling class imbalance to improve the performance of the XGBoost algorithm. Experiments were conducted by comparing a baseline model against models with resampling applied during preprocessing. Experimental results indicate that integrating the XGBoost algorithm with SMOTE significantly improves the Recall metric for the minority class compared to both the baseline and under-sampling models. This increased sensitivity proves that the hybrid method is highly effective and stable for implementation as an academic early warning system.

Keywords: student dropout, imbalanced data, resampling, SMOTE, XGBoost

1. PENDAHULUAN

Institusi pendidikan tinggi saat ini berhadapan dengan tuntutan besar untuk mempertahankan retensi mahasiswanya hingga lulus. Tingkat *dropout* tidak hanya mencerminkan hilangnya potensi akademis, tetapi juga berdampak pada evaluasi institusional. Seiring dengan ketersediaan data akademik yang masif, pemanfaatan algoritma *machine learning* dan *educational data mining* menjadi solusi strategis untuk membangun sistem deteksi dini bagi mahasiswa yang berisiko gagal menyelesaikan studinya [1].

Meskipun model *machine learning* mampu memproses variabel kompleks, penerapannya pada data riwayat pendidikan memiliki kendala mendasar. Dataset riwayat akademik mahasiswa umumnya tidak seimbang (*imbalanced data*), di mana jumlah mahasiswa yang *dropout* jauh lebih sedikit dibandingkan mahasiswa yang lulus atau bertahan [2]. Jika data ini langsung disuapkan pada algoritma tanpa intervensi, model akan cenderung bias dan memiliki akurasi semu yang tinggi, namun gagal mendeteksi dini mahasiswa yang berisiko *dropout*. Model hanya akan pandai mengenali kelas mayoritas dan mengabaikan kelas minoritas.

Untuk mengatasi paradoks akurasi tersebut, modifikasi pada tingkat data sangat diperlukan. Penelitian ini mengusulkan penerapan teknik *resampling* pada tahap pra-pemrosesan. Tujuan penelitian ini adalah menganalisis efektivitas perbandingan teknik *resampling* (*Synthetic Minority Over-sampling Technique* atau SMOTE dan *Random Under-Sampling*) dalam menangani ketidakseimbangan kelas guna meningkatkan performa algoritma XGBoost dalam memprediksi potensi *dropout* mahasiswa.

2. KAJIAN PUSTAKA


Karakteristik dataset pendidikan yang menjadi objek penelitian ini berpusat pada data demografi, sosial-ekonomi, dan kinerja akademik mahasiswa. Dataset yang digunakan bersumber dari repositori publik UCI Machine Learning yang bersifat terbuka untuk keperluan riset <https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success> [3]. Dalam menangani distribusi kelas yang timpang pada dataset tersebut, terdapat dua pendekatan utama. Pendekatan pertama adalah memperbanyak kelas minoritas secara sintesis menggunakan SMOTE, yang bekerja dengan menginterpolasi ruang fitur (*feature space*) antar sampel minoritas [2]. Pendekatan kedua adalah menggunakan *Random Under-Sampling* untuk mengurangi sampel mayoritas secara acak [4].

Algoritma *Extreme Gradient Boosting* (XGBoost) dipilih sebagai model klasifikasi utama karena kemampuannya yang tangguh berbasis pohon keputusan (*decision tree*) dan prinsip *ensemble learning*. Algoritma ini dinilai sangat efisien dalam menangani data tabular terstruktur berskala besar dan memiliki kapabilitas regularisasi bawaan untuk menekan laju bias prediksi [4].

3. METODE PENELITIAN

Penelitian ini menggunakan desain eksperimen komputasi terstruktur yang berfokus pada pendekatan berbasis data (*data-driven approach*) untuk mendeteksi dini potensi putus kuliah. Dataset sekunder yang digunakan berasal dari repositori terbuka UCI Machine Learning dengan judul *Predict Students' Dropout and Academic Success*. Secara keseluruhan, dataset mentah ini memiliki dimensi berupa 4.424 baris observasi dan 36 kolom fitur yang mencakup tipe data kategorikal dan numerikal. Sebelum masuk ke tahap pemodelan, dataset ini disaring terlebih dahulu dengan mengeliminasi sampel mahasiswa yang masih berstatus aktif (*Enrolled*), sehingga model difokuskan pada penyelesaian masalah klasifikasi biner, yaitu membedakan profil mahasiswa lulus (*Graduate*) dan mahasiswa yang putus kuliah (*Dropout*).

Sebelum dilakukan transformasi matematis pada data, tahap eksplorasi data (*Exploratory Data Analysis*) dilakukan guna mengidentifikasi pola anomali dan korelasi antar variabel. Analisis univariat dan bivariat diterapkan untuk menyoroti faktor-faktor dominan penyebab putus kuliah, di mana hasil visualisasinya dapat dilihat pada Gambar 1.



Gambar 1. Insight Ketidakseimbangan Target & Pengaruh Debtor terhadap Dropout

3.1. Prapemrosesan Data

Tahap selanjutnya adalah pra-pemrosesan data (*data preprocessing*). Proses ini sangat krusial untuk memastikan algoritma dapat belajar secara optimal. Target variabel kategori diubah menjadi format numerik menggunakan fungsi *Label Encoder*. Mengingat fitur-fitur akademik dan finansial di dalam dataset memiliki skala satuan yang jauh berbeda, dilakukan proses standardisasi menggunakan *Standard Scaler*. Hal ini memastikan tidak ada fitur dominan yang mengaburkan fitur lain selama proses kalkulasi matematis. Data kemudian dipartisi menjadi data latih (*training set*) sebesar 80% dan data uji (*testing set*) sebesar 20% menggunakan metode *stratified sampling* agar rasio kelas tetap terjaga pada kedua bagian data.

3.2. Imbalanced Data Solving

Untuk mengatasi permasalahan ketidakseimbangan kelas (*imbalanced data*) pada data latih, penelitian ini mengimplementasikan dua teknik *resampling* secara terpisah sebagai perbandingan. Teknik pertama adalah *Synthetic Minority Over-sampling Technique* (SMOTE) yang bekerja dengan cara mensintesis sampel buatan baru untuk kelas minoritas berdasarkan kedekatan jarak fitur (*k-nearest neighbors*). Teknik kedua adalah *Random Under-Sampling* yang memotong jumlah kelas mayoritas secara acak agar seimbang dengan jumlah kelas minoritas. Pendekatan hibrida tingkat data ini bertujuan untuk memperluas area batas keputusan model terhadap kelas *dropout*.

3.3. Tahap Pemodelan

Pada tahap pemodelan (*modeling*), algoritma *Extreme Gradient Boosting* (XGBoost) diaplikasikan sebagai arsitektur klasifikasi utama dengan algoritma *Random Forest* sebagai model pembanding. Proses pencarian parameter terbaik (*hyperparameter tuning*) untuk model XGBoost dilakukan secara otomatis menggunakan modul *GridSearchCV* guna menemukan kombinasi nilai *learning rate*, *max depth*, dan jumlah *estimators* yang paling meminimalkan fungsi kerugian logaritmik (*logloss*).

3.4. Evaluasi Model Kerja

Tahap terakhir dari metode ini adalah evaluasi kinerja model. Berbeda dengan pendekatan klasifikasi umum yang mengutamakan akurasi, performa deteksi pada penelitian ini dititikberatkan pada optimalisasi metrik *Recall*. Pemilihan metrik ini didasarkan pada kebutuhan sistem peringatan dini di mana meminimalkan kesalahan prediksi *False Negative* (sistem mendeteksi mahasiswa berstatus aman, padahal aslinya berisiko *dropout*) adalah prioritas mutlak yang harus diselesaikan oleh model kecerdasan buatan.


4. HASIL DAN PEMBAHASAN

Pembahasan terhadap hasil penelitian dan pengujian yang diperoleh dalam bentuk uraian teoritik baik secara kualitatif maupun kuantitatif. Eksperimen komputasi dilakukan untuk mengevaluasi dampak teknik *resampling* terhadap kinerja algoritma klasifikasi. Metrik evaluasi utama yang menjadi fokus penganalisaan adalah *Recall*, guna meminimalkan kesalahan prediksi pada kondisi di mana mahasiswa sebenarnya berisiko *dropout*, namun sistem menebaknya aman (*False Negative*). Perbandingan performa dapat dilihat pada Tabel 1.

Tabel 1. Perbandingan kinerja algoritma sebelum dan sesudah *resampling*


Model & Skenario Data	Accuracy	Precision	Recall
Random Forest (Baseline)	81%	85%	36%
Random Forest (SMOTE)	84%	76%	68%
XGBoost (Baseline)	83%	84%	40%
XGBoost (SMOTE)	86%	78%	82%

Berdasarkan data pada Tabel 1, terlihat jelas bahwa melatih algoritma menggunakan dataset asli (baseline) menghasilkan Recall yang sangat rendah. Namun, setelah kelas diseimbangkan menggunakan SMOTE, XGBoost mengalami lonjakan Recall mencapai 82%. Untuk memvalidasi keakuratan tersebut, sebaran klasifikasi dari XGBoost (SMOTE) divisualisasikan pada matriks kebingungan seperti yang terlihat pada Gambar 2.



Gambar 2. Matriks kebingungan model XGBoost dengan SMOTE

Merujuk pada Gambar 2, model berhasil menekan angka *False Negative* secara signifikan. Lebih lanjut, transparansi keputusan kecerdasan buatan ini diekstraksi menggunakan pustaka SHAP (*SHapley Additive exPlanations*). Urutan prioritas variabel yang paling menentukan keputusan *dropout* digambarkan pada Gambar 3.



Gambar 3. Urutan prioritas variabel yang paling menentukan keputusan *dropout*

Berdasarkan Gambar 3, faktor akademik dan finansial merupakan indikator terkuat. Nilai IPK pada semester awal dan kelancaran pembayaran uang kuliah menjadi parameter utama yang memengaruhi masa studi.

Berdasarkan hasil evaluasi model yang optimal, algoritma XGBoost (SMOTE) ini kemudian diintegrasikan ke dalam antarmuka berbasis web (*web-based interface*) menggunakan kerangka kerja Streamlit. Hal ini bertujuan agar sistem deteksi dini dapat digunakan secara interaktif oleh pihak manajemen akademik. Tampilan antarmuka aplikasi prediksi dapat dilihat pada Gambar 4.

Gambar 4. Antarmuka aplikasi prediksi *dropout* mahasiswa menggunakan Streamlit

5. KESIMPULAN

Berdasarkan rangkaian eksperimen komputasi dan analisis yang telah dilakukan, adapun simpulan dari penelitian ini adalah:

1. Ketidakseimbangan data (*imbalanced data*) pada rekam akademik secara fatal menyebabkan algoritma *machine learning* menjadi bias ke arah kelas mayoritas (mahasiswa lulus). Hal ini dibuktikan dengan metrik sensitivitas (*Recall*) pada model *baseline* XGBoost tanpa penanganan data yang sangat rendah, yakni hanya 40%, sehingga sistem akan gagal mendeteksi sebagian besar mahasiswa yang sebenarnya berisiko putus kuliah.
2. Integrasi algoritma XGBoost dengan teknik *resampling* SMOTE terbukti sebagai strategi optimasi yang paling superior dibandingkan dengan pendekatan *Random Under-Sampling*. Pendekatan SMOTE berhasil mempertahankan informasi historis dari kelas mayoritas sembari memperluas batas keputusan untuk kelas minoritas, yang dibuktikan dengan lonjakan metrik *Recall* secara drastis mencapai 82% dengan akurasi keseluruhan (*Accuracy*) yang tetap stabil di angka 86%.
3. Berdasarkan hasil interpretasi transparansi model menggunakan metode SHAP (*SHapley Additive exPlanations*), faktor capaian akademik dan pemenuhan kewajiban finansial merupakan indikator terkuat pemicu *dropout*. Nilai IPK mahasiswa pada dua semester awal serta kepemilikan riwayat tunggakan (status *Debtor*) menjadi parameter utama yang paling memengaruhi probabilitas kegagalan studi.

4. Secara keseluruhan, model sistem hibrida (XGBoost + SMOTE) yang dibangun mampu menekan angka *False Negative* dengan sangat baik. Sistem ini memiliki sensitivitas yang sangat tinggi dan ketahanan yang stabil, menjadikannya arsitektur yang sangat layak untuk diimplementasikan ke dalam sistem peringatan dini terpadu (*early warning system*) di perguruan tinggi.

6. SARAN

Berdasarkan hasil analisis dan kesimpulan yang telah diuraikan, adapun rekomendasi yang dapat diberikan adalah sebagai berikut:

1. Bagi Institusi Pendidikan: Sistem deteksi dini berbasis aplikasi web (Streamlit) yang dihasilkan dari penelitian ini direkomendasikan untuk diintegrasikan dengan Sistem Informasi Akademik (SIKAD) kampus. Pihak manajemen akademik dan dosen wali disarankan untuk segera melakukan intervensi dan pendampingan proaktif kepada mahasiswa yang diprediksi berisiko tinggi oleh sistem, terutama dengan mengevaluasi kelancaran finansial dan IPK mereka di awal semester.
 2. Bagi Pengembangan Penelitian: Untuk penelitian selanjutnya, direkomendasikan untuk mengeksplorasi penggunaan algoritma ensemble generasi terbaru lainnya seperti LightGBM atau CatBoost. Selain itu, penambahan fitur atau variabel psikologis mahasiswa dapat dilakukan untuk memperkaya dimensi prediksi.
-

DAFTAR PUSTAKA

- [1] A. Amalia dan A. Asmunin, "Analisis Perbandingan Metode SMOTE-ENN dan SMOTE-Tomek pada Klasifikasi Data Tidak Seimbang," *Jurnal Ilmiah Teknik Informatika dan Komputer (JTIK)*, vol. 5, no. 1, hal. 1-9, 2024.
 - [2] M. Imani, A. Beikmohammadi, dan H. R. Arabnia, "Comprehensive Analysis of Random Forest and XGBoost Performance with SMOTE, ADASYN, and GNUS under Varying Imbalance Levels," *Technologies*, vol. 13, no. 3, hal. 88, 2025.
 - [3] V. Realinho, J. Machado, L. Baptista, dan M. Martins, "Predicting Student Dropout and Academic Success," *Data*, vol. 7, no. 11, hal. 146, 2022.
 - [4] Sugihartono, "Integrating SMOTE with XGBoost for Robust Classification on Imbalanced Datasets: A Dual-Domain Evaluation," *Sinkron*, vol. 9, no. 1, 2025.
-